

DeepFact Validator

仕様解説書 v1.0

情報のObservabilityを社会に実装するマルチエージェントAI —— システム構成・信頼度判定ロジック・運用設計の体系解説

提出先 DevOps × AI Agent Hackathon 2026 (Findy/Google Cloud Japan協賛)

作成 株式会社Liberaiz 版 v1.0 取得日 2026年6月29日

プロダクト概要 DeepFact Validator は、ユーザーがネットを見ている瞬間に AI エージェントが情報の信頼度と利害関係をリアルタイム可視化するマルチエージェント・ブラウザ拡張です。医師である創業者の「真偽判断は一次情報まで遡る」習慣を AI で社会全体に拡張します。

技術スタック Vertex AI Gemini 2.5-flash/FastAPI/Cloud Run/Firestore/LINE Bot/Chrome Extension (Manifest V3)。決定化は seed=42 (ベストエフォート) + Firestore キャッシュ二層で同一入力一致を保証。

本書の目的 審査員が技術的詳細を確認できる体系資料。特に「信頼ドメイン辞書 (109件)」と「Yahoo等の配信プラットフォーム未登録の根拠」を FAQ で明示します。

SECTION 01

解決する課題と背景

誤情報・誇張広告・陰謀論型フェイクが医療領域に流入する現状で、ユーザーが疑問を持つ前に AI エージェントが能動介入し、信頼度スコア・構造観察・公的機関ソース URL を提供することで、医師の「一次情報まで遡る」習慣を社会全体に拡張します。

「素の Gemini で代替不可」5基準

- 状態継続：発信源の過去ポジショントーク蓄積
- 外部連携：複数ニュースAPI/SNS/論文DB/利害関係DB

3. 専門深さ：一次情報追跡＋利害関係分析
4. HITL：ユーザーが警告を見て判断
5. 業務自動化：常時監視→診断→アラート→警告履歴蓄積


SECTION 02

DevOps × AI Agent ストーリー

DEVOPS文脈	本プロダクトの実装
Observability	Cloud Logging／Monitoring で「ユーザーが見た情報履歴」を SRE的に蓄積・可視化・アラート
CI/CD	信頼ソース ホワイトリストを Git 管理・差分監視・ベクトルDB 自動再 deploy
SRE	「真実のSREエージェント」コンセプト・情報の障害（誤情報）を予兆検知
Postmortem	誤情報に騙された後の「警告履歴」を Postmortem 形式で記録・再発防止

SECTION 03

マルチエージェント構成



全エージェント: Vertex AI Gemini 2.5-flash × temperature=0.0 + seed=42 + top_k=1 (ベストエフォート) + Firestore キャッシュ二層で同一入力一致を完全保証。同一入力×3回で完全一致 (コンテストデモ事故ゼロ・決定化検証 PASS)。

3つの利用エントリ

1. **LINE Bot** : 友達追加だけで URL/テキスト送信 → 信頼度 + 判定エビデンスURL を 🌅 / ⚠️ / 🍷 / ✅ アイコン付きで即返信
2. **Chrome Extension (Manifest V3)** : 閲覧中ページに常時介入・DOMオーバーレイで信頼度メーターと構造観察を表示

SECTION 04

信頼度スコアリングロジック

最終的な信頼度スコアは以下3軸の加重平均で算出されます（具体重み付けは内部仕様）：

軸	範囲	判定根拠
<code>source_credibility_score</code> （発信元信頼度）	0.20-0.95	109ドメイン信頼辞書の照合結果
<code>position_bias_score</code> （中立性）	0.00-1.00	Vertex AI Gemini が論調バイアスを評価
<code>fact_consistency_score</code> （事実整合性）	0.00-1.00	第三者ソース照合 + 内的整合性判定

ラベル分類

スコア帯	ラベル	アイコン
0.80以上	高	✓
0.55-0.79	中	⚠
0.40-0.54	低	⚠
0.40未満	警告	💣

SECTION 05

信頼ドメイン辞書（109件）

発信元 URL のドメインを以下の辞書で照合します。サブドメインは `"." + 親ドメイン` で接頭辞攻撃（例：fakewho.int → who.int）を防止する設計。

国際機関（信頼度 0.78-0.95）

WHO（who.int）／国連（un.org）／IMF／世界銀行／UNICEF／UNDP／UNHCR／UNESCO／OECD／ICRC／ICJ／WTO／Amnesty／Human Rights Watch

日本政府（0.90-0.95）

厚労省（mhlw.go.jp）／総務省／経産省／財務省／文科省／首相官邸／総務省統計局／PMDA
（医薬品医療機器総合機構）／金融庁／国立感染症研究所／国立がん研究センター／国立国際医療研究センター／国立成育医療研究センター

米国政府（0.85-0.95）

CDC／FDA／NIH／ホワイトハウス／国務省／連邦議会／連邦最高裁

各国政府（0.85-0.95）

NHS UK／英国政府／EU／カナダ政府／ドイツ連邦政府

学術機関・データベース（0.65-0.95）

PubMed／Nature／Science／NEJM／The Lancet／Cochrane／ClinicalTrials.gov／arXiv／
bioRxiv／medRxiv／JSTOR／Semantic Scholar／Google Scholar／CiNii／J-STAGE

日本主要報道（0.72-0.82）

NHK／朝日新聞／日経／読売／毎日／産経／時事通信／共同通信／東洋経済／ダイヤモンド／
プレジデント／Newsweek 日本版／日経BP

国際報道（0.78-0.85）

Reuters／AP／BBC／Bloomberg／Financial Times／NYT／Washington Post／WSJ／The
Guardian／NPR／PBS／ABC オーストラリア／Deutsche Welle

ファクトチェック団体（IFCN加盟＋日本系・0.78-0.92）

日本ファクトチェックセンター JFC／FIJ／FactCheck.org／Snopes／PolitiFact／Full Fact UK／
AFP Fact Check／Reuters Fact Check／Lead Stories／Factly India／MediaWise Poynter

専門団体・データプロバイダ（0.85）

帝国データバンク／東京商工リサーチ／日本医師会／Mayo Clinic

オープン情報

Wikipedia（0.65・noise filter 47キーワードで誤ヒット記事除外）

既知信頼性問題媒体（プロパガンダ判定・0.20-0.45）

TASS（ロシア国営）／RT／Sputnik／RIA／環球時報（中国国営）／新華社／人民日報／Press
TV（イラン国営）／朝鮮中央通信

FAQ：頻出する疑問への回答

Q1. なぜ Yahoo!ニュース (news.yahoo.co.jp) は「未登録」になるのか？

Yahoo!ニュース はニュース配信プラットフォームで、記事の元出典は各新聞社・通信社からの転載です。配信元の信頼度を直接保証する仕組みがないため、辞書には意図的に登録していません。

判定ロジック (`_classify_source` 関数) :

1. ドメインが TRUSTED_DOMAINS に登録 → そのスコア返却
2. サブドメインが信頼ドメインの一部 → 親ドメインのスコア
3. それ以外 → 「未登録」スコア 0.50 ・ カテゴリ unknown

これは「Yahoo を疑っている」のではなく、「Yahoo は配信プラットフォームなので、元配信元 (朝日／読売／共同等) に辿ってから判定するのが正確」という設計判断です。同様に SmartNews／NewsPicks／Gunosy／Google News／MSN ニュース等も配信プラットフォームとして未登録扱いです。

v1.1で実装予定の改善：配信プラットフォーム検出時に HTML から元配信元を抽出 (`<meta property="article:publisher">` /JSON-LD `publisher.name` /Yahoo固有「提供：朝日新聞デジタル」テキスト等) し、TRUSTED_DOMAINS で再判定。表示例：「Yahoo!ニュース 経由／元配信元: 朝日新聞 (信頼度 0.75)」

Q2. 信頼度スコアはどう算出している？

3軸 (発信元信頼度 / 中立性 / 事実整合性) を加重平均。プロパガンダパターン検出時は煽動キーワード辞書 (5カテゴリ×100+キーワード) で減点。第三者ソース照合 (Google Fact Check Tools + Wikipedia) の結果も加味。

Q3. 同じ記事を分析すると毎回違うスコアが出るのでは？

Vertex AI Gemini の `seed=42` (ベストエフォート) に加え、Firestore キャッシュ二層で同一入力ハッシュをキー化して結果を保存。これにより同一入力×3回で完全一致を実証 (コンテストデモ事故ゼロ)。

Q4. 個人ジャーナリストや特定企業を攻撃したりしないか？

Brand Soul 原則「個人・組織への断定攻撃を避け、情報構造を可視化する」を全レポートに常設。「〇〇という構造」「〇〇の傾向」形式のみで提示し、政治的・宗教的に微妙な主張は「複数の立場が成り立つ構造」を `contrarian_views` で提示します。

Q5. プロンプトインジェクション対策は？

Watcher / Investigator / Validator の各エージェントで入力テキストをサニタイズ。Gemini への指示文（システムプロンプト）と入力テキスト（ユーザー部分）を構造的に分離。さらに信頼ドメイン辞書のサブドメイン照合で `fakewho.int` のような接頭辞攻撃を防止（`domain.endswith("." + trusted_root)` 形式）。

SECTION 07

第三者ソース能動取得

誇張広告・陰謀論・フェイク主張を検出すると、以下を能動的に取得して上位表示：

- Google Fact Check Tools API（IFCN 加盟ファクトチェック団体・ja+en 並列叩き）
- Wikipedia REST API（無料・登録不要・ja+en 並列・47キーワード noise filter）
- 公的機関ソース 上位常時挿入：厚労省／PMDA／WHO／CDC／総務省／JFC／Snopes／PolitiFact／FullFact／Reuters Fact Check／AFP Fact Check

全体 15秒 timeout + httpx 5秒 + retry 1回で本番運用適格。「Wikipedia オンリー」構造を完全排除し、公的機関の直接URLを優先表示。

SECTION 08

実機検証結果（v0.3）

#	入力パターン	信頼度	ラベル
1	フェイク主張（証拠なきジェノサイド）	20%	警告
2	厚労省 一次情報URL	98%	高
3	中立報道風（賛否両論）	59%	中
4	誇張広告（3日でガン消失）	20%	警告
5	ワクチンフェイク（陰謀論型）	25%	警告

結果 98% vs 20% = 78ポイント振れ幅（入力依存性完全確認）。同一入力×3回で完全一致（決定化検証 PASS・コンテストデモ事故ゼロ）。

SECTION 09

既存サービスとの差別化

既存	何ができる	DEEFACT VALIDATOR	差分
NewsGuard	信頼度スコア（人手評価）	+ AI Agent 能動介入	静的 → 動的
Ground News	複数視点並列表示	+ 利害関係グラフ可視化	並べる → 関係性で診る
AllSides	左右ラベル	+ ユーザー文脈パーソナライズ	一律 → 個別
ChatGPT / Gemini	質問→回答	+ 質問前に能動介入	受動 → 能動

SECTION 10

法的リスク対策（Brand Soul「品格」継承）

「人を攻撃しない・構造を可視化する」原則を全レポートに常設：

- 禁則表現：「このジャーナリストは〇〇から金もらってる」「この記事は嘘」「個人を断定攻撃」
- 推奨表現：「この記事の出所と過去発言には XX という構造的関係がある」「一次情報と比較すると〇〇の点で論調が異なる」
- 政治的・宗教的に微妙な主張：「複数の立場が成り立つ構造」を `contrarian_views` で提示

SECTION 11

今後の改善計画（v1.1+）

機能	内容	優先度
元配信元抽出（マス）	Yahoo!ニュースに限らず、 配信プラットフォーム全般 （SmartNews／NewsPicks／Gunosy／Google News／MSN ニュース等）の検出時、HTML から元配信元を抽出して TRUSTED_DOMAINS で再判定。「配信プラットフォーム → 未登録」の盲点を構造的に解消する必須機能（FAQ Q1 参照）	最優先
ジャーナリスト発言履歴DB	個別ライターの過去ポジショントークを Firestore で蓄積・参照	中
メディア×スポンサー関係グラフ	利害関係を可視化するインタラクティブグラフ	中
Vertex AI Vector Search 移行	類似主張照合を Firestore + cosine から本番 Vector Search index へ	低

APPENDIX

出典・参照URL

- デプロイ済 URL: <https://deepfact-validator-kjciocymea-an.a.run.app>
- Cloud Run リビジョン: deepfact-validator-00031-fq4 (v0.4.13)
- ソースコード: [marketing/hackathon-2026/deepfact-validator/src/](https://github.com/marketing/hackathon-2026/deepfact-validator/src/)
- Chrome Extension: [marketing/hackathon-2026/deepfact-validator/extension/](https://github.com/marketing/hackathon-2026/deepfact-validator/extension/) (Manifest V3)
- 関連ドキュメント: README.md／submission/1pager.md／submission/proto-pedia-overview.md／submission/SUBMISSION-CHECKLIST.md